

**UNIVERSIDADE CATÓLICA DE PETRÓPOLIS CENTRO DE CIÊNCIAS SOCIAIS
APLICADAS
TECNÓLOGO EM CIÊNCIA DE DADOS E BUSINESS INTELLIGENCE**

**APLICAÇÃO DE TÉCNICAS DE CIÊNCIA DE DADOS E MACHINE LEARNING
PARA ANÁLISE E PREDIÇÃO DE RISCOS EM PROJETOS**

GIOVANA WINTER

Petrópolis

2026

1. INTRODUÇÃO

O gerenciamento de projetos tem assumido papel cada vez mais estratégico crucial nas organizações contemporâneas, uma vez que projetos são amplamente utilizados para promover inovação, implementar mudanças organizacionais, desenvolver produtos e alcançar objetivos alinhados ao planejamento estratégico. Porém, a complexidade crescente dos ambientes corporativos associada à vertiginosa evolução tecnológica, à volatilidade dos mercados e à limitação de recursos, torna a execução de projetos uma atividade sujeita a diversos níveis de incerteza, intitulados riscos (PROJECT MANAGEMENT INSTITUTE, 2021).

A gestão de riscos destaca-se como uma das principais áreas no gerenciamento de projetos, pois a identificação precoce dos riscos possibilita a adoção de medidas preventivas e corretivas capazes de minimizar impactos sobre prazo, custo, escopo e qualidade. Segundo o Project Management Institute (2021), o gerenciamento de riscos compreende processos destinados a identificar, analisar, monitorar e responder a eventos que possam impactar os objetivos do projeto, sejam estes impactos positivos ou negativos. Suplementarmente, a norma ABNT NBR ISO 31010 enfatiza que a avaliação sistemática dos riscos é decisiva no apoio a tomada de decisão e aumenta a capacidade das organizações em lidar com incertezas (ABNT, 2012).

Nesse cenário, a Ciência de Dados e o Machine Learning surgem como alternativas capazes de complementar as práticas tradicionais de gerenciamento de riscos. Fornecem suporte quantitativo para a tomada de decisão por meio da análise de grandes volumes de dados. Possibilitam a identificação de padrões, relações e tendências que improvavelmente seriam percebidos por métodos convencionais (MEDEIROS; GOMES, 2021).

O presente estudo tem como objetivo analisar fatores associados aos riscos em projetos e avaliar a aplicação do algoritmo de aprendizado de máquina Random Forest, método proposto por Breiman (2001), na classificação de diferentes níveis de risco. O algoritmo baseia-se na combinação de múltiplas árvores de decisão, permitindo a construção de modelos preditivos capazes de lidar com conjuntos de dados complexos e compostos por diversas variáveis explicativas (BREIMAN, 2001). Para isso, foi utilizada um dataset contendo dados relacionados ao gerenciamento de projetos.

A relevância desta pesquisa está na possibilidade de demonstrar como técnicas de Ciência de Dados podem enriquecer as práticas tradicionais do gerenciamento de projetos,

oferecendo suporte analítico na identificação, classificação e monitoramento de riscos. Espera-se contribuir para o desenvolvimento de abordagens orientadas por dados, capazes de apoiar gestores na tomada de decisões e ampliar significativamente as chances de sucesso dos projetos em ambientes cada vez mais complexos e dinâmicos.

2. OBJETO

De acordo com Project Management Institute (PROJECT MANAGEMENT INSTITUTE, 2021), riscos são eventos não controlados que podem impactar positiva ou negativamente o desenvolvimento de um projeto. O gerenciamento de riscos é uma área essencial do gerenciamento de projetos, ele consiste em um conjunto de técnicas aplicadas a identificação e análise de riscos que podem afetar a performance de um projeto.

Visando mitigar os possíveis impactos dos riscos, especialmente em ambientes complexos e orientados a dados, faz-se fundamental a utilização de perspectivas quantitativas e analíticas para melhor compreensão desses fenômenos. Segundo a ISO 31010:2012, a utilização de ferramentas para avaliar e compreender a natureza de um risco e classificá-lo de acordo com sua probabilidade de ocorrência e consequência caso ocorra é fundamental para a tomada de decisões estratégicas dentro de um projeto. A aplicação de tais técnicas é crucial para apoiar a tomada de decisão e a hierarquização das ações necessárias para a concretização do objetivo.

Com isso em mente, o presente trabalho objetiva a análise de riscos associados a projetos, tendo com ponto de partida a aplicação de técnicas de Ciência de Dados para a identificação de padrões, tendências e relações entre variáveis que influenciam no resultado de um projeto, e do algoritmo de Machine Learning Random Forest para classificar os projetos de acordo com diferentes categorias de risco, viabilizando o desenvolvimento de abordagens quantitativas aplicadas ao gerenciamento de projetos.

3. JUSTIFICATIVA

O aumento na complexidade dos projetos, em conjunto com a indispensabilidade de tomadas de decisão mais assertivas, torna o gerenciamento de riscos uma prioridade nas organizações. A gestão de riscos é crucial para o aumento da probabilidade de sucesso dos projetos, pois possibilita antecipação de problemas e a definição de respostas estratégicas satisfatórias (PROJECT MANAGEMENT INSTITUTE, 2021). Nesse contexto, profissionais

capazes de utilizar técnicas de ciência de dados para extrair padrões e insights de grandes conjuntos de dados, se tornam um forte diferencial estratégico em uma empresa, pois eles proporcionam conhecimento a partir de dados brutos, que são necessários para a tomada de decisões estratégicas assertivas, mitigação de falhas e, principalmente, a análise e identificação de riscos.

Ademais, a ISO 31010:2012 discorre que a aplicação de técnicas estruturadas de análise de risco possibilita maior confiança nas decisões, comprimindo incertezas e viabilizando melhora na performance institucional. Desse modo, a utilização de ferramentas quantitativas e analíticas torna-se progressivamente mais relevante, em especial quando vinculada a grandes quantidades de dados.

Tendo em vista tanto o contexto acadêmico quanto a aplicação prática, o emprego da análise de dados no gerenciamento de riscos fornece uma visão mais abrangente e estratégica das organizações, e possibilita a identificação de padrões que dificilmente seriam percebidos utilizando metodologias tradicionais (MEDEIROS; GOMES, 2021). De igual maneira, a aplicação de técnicas de *machine learning* permite a criação de modelos para a identificação antecipada e classificação de riscos, propiciando a escolha de planos mais eficazes e orientados a dados para o alcance dos objetivos da empresa.

A utilização de um *dataset* que contém dados de diferentes projetos permite a realização de análises exploratórias e a criação de modelos preditivos, que colaboram com a identificação das variáveis que influenciam no agravamento dos riscos de um projeto. No contexto da ciência de dados, que tem como objetivo compreender padrões relevantes, identificar oportunidades para resolver problemas, e extrair *insights* importantes de dados brutos, tal perspectiva organizacional é especialmente relevante.

Portanto, a execução do presente projeto justifica-se por sua colaboração na coligação entre a ciência de dados e o gerenciamento de projetos, possibilitando uma perspectiva detalhada e orientada à dados para a análise de riscos.

4. OBJETIVOS

4.1 Objetivo Geral

Realizar a aplicação de técnicas de Ciência de Dados e Machine Learning para analisar e identificar fatores associados aos riscos em projetos, tendo em vista o reconhecimento de padrões relevantes e avaliação da capacidade preditiva do algoritmo Random Forest na

classificação dos níveis de risco.

4.2 Objetivos Específicos

- i) Carregar, inspecionar e tratar o dataset, identificando e removendo valores ausentes, registros duplicados e variáveis com baixa representatividade, para assegurar a qualidade e a consistência dos dados utilizados.
- ii) Utilizar medidas estatísticas e representações gráficas para desenvolver análises exploratórias e descritivas de maneira mais intuitiva e visual, com o objetivo de compreender a distribuição das variáveis e identificar padrões relevantes para a modelagem preditiva.
- iii) Investigar as relações entre a variável-alvo Risk_Level e as demais variáveis, para descobrir os potenciais atributos associados aos níveis de risco.
- iv) Empregar o algoritmo Random Forest no desenvolvimento e avaliação de um modelo de classificação multiclasse para a predição dos níveis de risco dos projetos, utilizando métricas como acurácia, precisão, recall e F1-score.
- v) Relacionar os resultados obtidos às práticas propostas pela ISO 31010:2012, demonstrando a relevância da abordagem orientada a dados ao apoio à tomada de decisão.

5. METODOLOGIA

Tendo como objetivo identificar padrões e prever o nível de risco associado a projeto, o presente trabalho fez uso da base de dados denominada Project Management Risk Raw Dataset, obtida na plataforma Kaggle. O conjunto foi construído com auxílio de inteligência artificial para simular cenários reais de gerenciamento de projetos para fins educacionais. Em sua forma original, contém 4.000 observações e 51 variáveis, compreendendo diversas características de projetos e seus respectivos níveis de risco. Por tratar-se de dados sintéticos, não há um intervalo de tempo real associado.

A análise foi realizada por meio da linguagem Python, utilizando as bibliotecas Pandas, Matplotlib, Seaborn e Scikit-learn, seguindo um fluxo de trabalho estruturado em três fases principais: preparação dos dados, análise exploratória e modelagem preditiva.

A priori, foi realizada a preparação dos dados, o que incluiu inspeção estrutural da base escolhida, identificação de valores ausentes, remoção de registros duplicados e exclusão de variáveis com alta proporção de dados faltantes. Como critério de qualidade, foram removidas colunas que apresentavam mais de 40% de valores ausentes, pois uma grande quantia de dados faltantes pode comprometer drasticamente a representatividade das variáveis e enviesar as análises, bem como os registros incompletos nas variáveis remanescentes, que poderiam comprometer a confiabilidade e a qualidade do conjunto de dados durante a análise exploratória e a aplicação do Random Forest. Após o processo de limpeza, a base final passou a conter 2.701 observações e 50 variáveis.

A Análise Exploratória de Dados (AED), foi conduzida através da utilização de medidas estatísticas descritivas e técnicas de visualização de dados. Essa etapa teve como finalidade compreender a distribuição das variáveis, identificar padrões associados aos níveis de risco e fornecer recursos para a modelagem preditiva.

O algoritmo Random Forest foi utilizado no modelo de Machine Learning, sua seleção foi realizada em função de sua capacidade de lidar com conjuntos de dados multivariados, sua robustez frente a ruídos e sua eficiência em problemas de classificação multiclasse. As variáveis categóricas foram previamente convertidas para a representação numérica por meio da técnica Label Encoding, possibilitando sua utilização pelo Random Forest, que é um algoritmo matemático, ou seja, trabalha com números.

Posteriormente, os dados foram divididos em conjuntos, 70% para treinamento e 30% para teste. A estratificação das classes foi utilizada para preservar a distribuição original dos níveis de risco.

Enfim, o desempenho do modelo foi avaliado por meio das métricas de acurácia, precisão, recall e F1-score. De igual modo, foi empregada validação cruzada estratificada com cinco partições, com o objetivo de aumentar a confiabilidade dos resultados e reduzir os efeitos decorrentes da divisão específica dos dados, garantindo que o desempenho do modelo fosse avaliado em diferentes subconjuntos da base e produzisse resultados mais representativos e confiáveis.

5.1 Análise Descritiva e Exploratória dos Dados

Nesta etapa foi possível compreender as características gerais da base e identificar fatores potencialmente associados aos diferentes níveis de risco dos projetos.

Contando com 2.701 projetos distribuídos em quatro categorias de risco: Low, Medium, High e Critical., observou-se um desbalanceamento entre as classes, com predominância significativa da categoria Medium (37,3%), seguida por Low (25,8%), High (23,8%) e Critical (13,1%).




Figura 1 – Distribuição do Nível de Risco dos Projetos
Fonte: Autora (2026)

A avaliação das estatísticas descritivas das variáveis numéricas evidenciou que os projetos analisados apresentam ampla variabilidade. O tamanho médio aproximado das equipes foi de 15 integrantes, a média de complexidade dos projetos foi de 6,18 (com base em uma escala de 1 a 10). Tais resultados indicam os projetos analisados na amostra apresentam diferentes portes e complexidades.




Figura 2 – Distribuição das Variáveis Numéricas
Fonte: Autora (2026)

A análise das variáveis categóricas revelou que projetos da área de Tecnologia da

Informação representam aproximadamente 37% dos registros. Paralelamente, observou-se que há maior frequência na utilização de metodologias de abordagens ágeis, em especial Agile e Scrum, o que evidencia a relevância dessas práticas para o contexto em análise.

A distribuição dos níveis de risco por tipo de projeto indicou diferenças entre as áreas avaliadas. Projetos classificados como Pesquisa e Desenvolvimento apresentaram as maiores proporções em riscos classificados como elevados e críticos, enquanto projetos das áreas de Saúde e Manufatura mantiveram percentuais elevados em riscos baixos ou médios.




Figura 3 – Proporção do Nível de Risco por Tipo de Projeto

Fonte: Autora (2026)

A comparação entre os projetos classificados como críticos e os restantes revelou diferenças interessantes em determinadas variáveis. A maior discrepância foi vista na variável Complexity_Score, cuja média foi aproximadamente 1,9 ponto superior nos projetos críticos. Também foram identificados valores mais elevados para rotatividade da equipe, complexidade de integração e utilização do orçamento, o que sugere que esses fatores contribuem para o aumento do nível de risco dos projetos. Estes resultados foram reforçados através da aplicação das análises gráficas.




Figura 4 – Complexidade do Projeto por Nível de Risco

Fonte: Autora (2026)




Figura 5 – Variáveis Numéricas por Nível de Risco

Fonte: Autora (2026)




Figura 6 – Heatmap de Correlação entre as Variáveis Numéricas
Fonte: Autora (2026)

Em geral, por meio da análise exploratória foi possível a identificação de padrões consistentes entre certas características dos projetos e seus respectivos níveis de risco, o que fornece evidências relevantes para a modelagem preditiva.

6. APLICAÇÃO DE MACHINE LEARNING: RANDOM FOREST

6.1 Apresentação Teórica do Método

O Random Forest é um algoritmo de aprendizado supervisionado que pertence à categoria dos algoritmos de ensemble learning, cuja principal característica é a combinação de múltiplos modelos para produzir previsões mais robustas, o método foi proposto por Leo Breiman em 2001 (SILVA et al., 2023).

O conjunto é formado por diversas árvores de decisão, durante o treinamento do modelo, várias amostras são geradas partindo da base original. Cada amostra é utilizada para construir uma árvore de decisão independente. Ao final do processo, as previsões produzidas por todas as árvores são combinadas por meio de votação majoritária, sendo a final escolhida

a classe mais frequentemente indicada pelo conjunto, o que torna o modelo mais robusto e com uma maior capacidade de generalização em relação a outros métodos, como a Árvore de Decisão individual (SILVA et al., 2023).

Objetivo do método

O algoritmo foi aplicado visando a classificação dos projetos em quatro categorias de risco: Low, Medium, High e Critical. Com o objetivo de apoiar a identificação e classificação dos níveis de risco dos projetos.

Principais características e vantagens do Random Forrest

O algoritmo apresenta numerosas características que justificam sua aplicação em problemas de classificação multiclasse em cenários que envolvem grande quantidade de variáveis e relações complexas entre os dados, entre elas:

- Reduz a variabilidade das árvores de decisão individuais;
- Aumenta consideravelmente a capacidade de generalização do modelo;
- Possui boa resistência à ruídos nos dados;
- Permite a identificação da importância relativa de cada variável nas previsões realizadas.

Essas características o tornaram atrativo para a aplicação em dados relacionados a projetos onde fatores organizacionais, técnicos, humanos e operacionais interagem de forma não linear.

Limitações do método

O modelo pode demandar um custo computacional maior por conta do treinamento de múltiplas árvores, além de que possui menor interpretabilidade se comparado a uma única árvore de decisão.

Ademais, bases sintéticas com relações artificiais entre variáveis podem não refletir integralmente o comportamento em ambientes reais.

6.2 Parâmetros Utilizados no Modelo

Para que fosse possível o desenvolvimento do modelo preditivo, foram utilizados os seguintes hiperparâmetros:

- `n_estimators = 300`: define a construção de 300 árvores de decisão;

- `max_depth = 20`: limita a profundidade máxima das árvores, reduzindo riscos de overfitting;
- `min_samples_split = 5`: estabelece o número mínimo de observações necessárias para dividir um nó;
- `min_samples_leaf = 2`: define o número mínimo de observações em cada folha terminal;
- `class_weight = balanced`: ajusta os pesos das classes por sua frequência na base de dados, o que reduz impactos do desbalanceamento das classes;
- `random_state = 42`: garante reprodutibilidade dos resultados obtidos.

Esses parâmetros foram definidos objetivando um modelo mais estável, com risco de sobreajuste reduzido e melhor capacidade de generalização das previsões.

6.3 Forma de Interpretação dos Resultados

A interpretação dos resultados da aplicação do modelo foi realizada através de métricas amplamente difundidas e aplicadas em problemas de classificação:

- **Acurácia**: mede a proporção geral de classificações corretas feitas pelo modelo em relação ao total de observações analisadas.
- **Precisão**: indica quantas previsões realizadas para determinada classe foram efetivamente corretas, é crucial na avaliação da confiabilidade das classificações produzidas pelo modelo.
- **Recall**: mede a capacidade do modelo de identificar corretamente os projetos pertencentes a cada categoria de risco.
- **F1-score**: média harmônica entre a precisão e o recall, fornece uma medida equilibrada do desempenho do modelo para cada classe.
- **Matriz de Confusão**: permite visualizar os acertos e erros de classificação entre as diferentes categorias de risco.
- **Importância das Variáveis**: o algoritmo calcula quanto cada atributo contribuiu para as previsões realizadas, o que permite a identificação de quais fatores exerceram maior influência na classificação dos níveis de risco.

6.4 Aplicação do Método no Estudo

Neste trabalho, o Random Forest foi aplicado à base de dados Project Risk Management Dataset tratada, contendo 2.701 observações e 50 variáveis. As variáveis categóricas foram convertidas para representação numérica através da aplicação da técnica Label Encoding, o que possibilitou a utilização pelo algoritmo.

Os dados foram divididos em conjuntos de treinamento e teste, utilizando a proporção de 70% para treinamento e 30% para teste, para preservar a distribuição original foi feita a estratificação das classes.

6.5 Resultados Obtidos

O modelo Random Forest apresentou na validação cruzada estratificada com cinco partições a acurácia média de 55,24%, com desvio padrão de 2,45%, o que indica uma relativa estabilidade entre os diferentes subconjuntos avaliados. Quando aplicado ao conjunto de teste, o modelo obteve acurácia de 57,95%.

As categorias Low e Medium obtiveram melhor desempenho, segundo as métricas de precisão, recall e F1-score. Em contrapartida, as categorias High e Critical apresentaram maiores dificuldades de classificação.




Figura 7 – Matriz de Confusão: Random Forest

Fonte: Autora (2026)




Figura 8 – Acurácia por Fold: Validação Cruzada (5-fold)

Fonte: Autora (2026)




Figura 9 – Importância das Variáveis: Random Forest

Fonte: Autora (2026)

A análise da importância das variáveis indicou que os fatores relacionados à complexidade do projeto, rotatividade da equipe, complexidade de integração e utilização do orçamento exerceram influência clara na classificação dos riscos.

6.6 Contribuição do Método para a Prevenção de Riscos em Projetos

A aplicação do Random Forest no presente estudo demonstra como técnicas de Ciência de Dados e Aprendizado de Máquina podem apoiar o gerenciamento de riscos em projetos. O modelo não substitui as práticas tradicionais de gestão de riscos, mas atua como uma relevante ferramenta complementar que é capaz de:

- identificar padrões relevantes nos dados;
- classificar projetos de acordo com seus níveis de risco;
- fornecer subsídios quantitativos para a tomada de decisão;
- auxiliar na identificação de fatores críticos associados ao aumento dos riscos.

Assim, o método contribui para abordagens orientadas por dados, capazes de apoiar gestores na prevenção, monitoramento e mitigação de riscos em ambientes organizacionais complexos.

7. LIMITAÇÕES DA PESQUISA

A principal limitação refere-se à natureza da base de dados que foi empregada na pesquisa. O conjunto de dados utilizado foi obtido a partir do Project Risk Management Dataset, disponibilizado na plataforma Kaggle e construído por meio de dados simulados com apoio de Inteligência Artificial. Embora a base tenha sido elaborada para representar cenários plausíveis de gerenciamento de projetos, as relações existentes entre as variáveis não foram observadas em projetos reais, mas sim geradas artificialmente, de forma que os resultados obtidos possuem caráter predominantemente acadêmico e devem ser analisados com cautela se generalizados para ambientes organizacionais reais.

Outra limitação está relacionada ao desempenho do modelo, o algoritmo Random Forest alcançou acurácia de 57,95% no conjunto de teste e acurácia média de 55,24% durante a validação cruzada. Os resultados demonstram a capacidade de identificar padrões associados aos níveis de risco, mas o desempenho indica que uma parcela significativa dos projetos foi classificada incorretamente. Tal fato sugere que os fatores disponíveis na base podem não ser suficientes para explicar os níveis de risco, ou que as relações entre as variáveis apresentam complexidade superior à capacidade do Random Forest.

Por fim, teve como foco a análise de uma única base de dados e em um único contexto de aplicação. Assim, futuras investigações que envolvam bases reais poderão fornecer evidências a respeito da contribuição da Ciência de Dados para o gerenciamento e a prevenção de riscos em projetos.

8. CONCLUSÃO

O projeto teve como objetivo analisar como técnicas de Ciência de Dados e Aprendizado de Máquina podem contribuir para a prevenção e o gerenciamento de riscos em projetos. Para a execução foi utilizado um dataset com informações relacionadas a características organizacionais, técnicas, humanas e operacionais dos projetos, sobre a qual foram realizadas a preparação dos dados, análise exploratória e modelagem preditiva.

Os resultados da análise exploratória permitiram identificar padrões relevantes associados aos diferentes níveis de risco. Variáveis relacionadas à complexidade dos projetos, à rotatividade das equipes, à complexidade de integração e à utilização do orçamento apresentaram diferenças significativas entre projetos classificados em níveis distintos de risco, evidenciando fatores potencialmente interessantes para o monitoramento e mitigação de riscos.

A performance do algoritmo Random Forest como ferramenta de apoio à classificação dos níveis de risco demonstra que técnicas de aprendizado de máquina são capazes de identificar relações entre múltiplas variáveis e gerar informações úteis para apoiar processos decisórios relacionados ao gerenciamento de projetos, embora o modelo tenha apresentado acurácia moderada.

O principal resultado desta pesquisa consiste na evidenciação do potencial da Ciência de Dados como instrumento de apoio à gestão de riscos. Foi possível dados brutos em conhecimento capaz de auxiliar a identificação de fatores críticos, a compreensão dos riscos e o desenvolvimento de ações preventivas para o aumento do sucesso em projetos.

Assim conclui-se que a integração entre Ciência de Dados, Aprendizado de Máquina e gerenciamento de projetos representa uma abordagem promissora e relevante no apoio à tomada de decisão estratégica em ambientes caracterizados por elevada complexidade e incerteza. Apesar das limitações relacionadas à natureza da base de dados e ao desempenho do modelo desenvolvido, os resultados obtidos demonstram que métodos analíticos podem complementar as práticas tradicionais de gerenciamento de riscos, contribuindo para decisões melhor fundamentadas e para o fortalecimento da gestão baseada em evidências.

9. REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **ABNT NBR ISO/IEC 31010:2012**: gestão de riscos — técnicas para o processo de avaliação de riscos. Rio de Janeiro: ABNT, 2012. Disponível em: https://wp.ufpel.edu.br/labserg/files/2022/04/abnt_nbr_iso_31010_2012__gestao_de_riscos_-_tecnicas_para_o_processo_de_avaliacao_de_riscos.pdf. Acesso em: 19 mar. 2026.

CARVALHO, André C. P. L. F. de; MENEZES, Angelo Garangau; BONIDIA, Robson Parmezan. **Ciência de Dados**: fundamentos e aplicações. Rio de Janeiro: LTC, 2024. E-book. ISBN 9788521638766. Disponível em: <https://integrada.minhabiblioteca.com.br/reader/books/9788521638766/>. Acesso em: 10 jun. 2026.

MEDEIROS, Thiago Alessandro Farias de; GOMES, Luiz Flávio Autran Monteiro. MACHINE LEARNING E ANÁLISE DE RISCOS: IDENTIFICANDO DESVIOS DE VIESES. **Tecnologia e Informação**: Revista do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca Cefet/RJ, Rio de Janeiro, p. 8-17, jul. 2021. Disponível em: https://www.cefet-rj.br/attachments/article/195/revista-n38_compressed.pdf#page=7. Acesso em: 10 mar. 2026.

NETTO, Amilcar; MACIEL, Francisco. **Python para Data Science e Machine Learning Descomplicado**. Rio de Janeiro: Alta Books, 2021. E-book. ISBN 9786555203172. Disponível em: <https://integrada.minhabiblioteca.com.br/reader/books/9786555203172/>. Acesso em: 16 abr. 2026.

PROJECT MANAGEMENT INSTITUTE (ed.). **Padrão de gerenciamento de projetos e Guia do conhecimento em gerenciamento de projetos (Guia PMBOK)**: e o padrão de gerenciamento de projetos. 7. ed. Pennsylvania: Project Management Institute, 2021. 370 p. Disponível em: <https://www.academiaplaorc.com.br/wp-content/uploads/2024/07/GuiaPMBOK-7a-Edicao.pdf>. Acesso em: 08 fev. 2026.

SILVA, Celso Barreto; GOMES, Fabio Fonseca Barbosa; SANTOS, José Vicente Cardoso; SANTOS, Cevaldo Santos e. **Uma análise comparativa das técnicas de Machine Learning**: Regressão Logística, Árvores de Decisão, Random Forest e SVM. **Apoena**, v. 7, p. 501–511, 2023. Disponível em: <https://publicacoes.unijorge.com.br/apoena/article/view/183>. Acesso em: 30 mai. 2026.

TATSAT, Hariom; PURI, Sahil; LOOKABAUGH, Brad. **Blueprints de aprendizado de máquina e ciência de dados para finanças**: desenvolvendo desde estratégias de trades até robôs Advisors com Python. Tradução: Alberto Streicher. Rio de Janeiro: Alta Books, 2024. E-book. ISBN 9788550821726. Disponível em: <https://integrada.minhabiblioteca.com.br/reader/books/9788550821726>. Acesso em: 28 mai. 2026.